

ONLINE RETAIL VERİ SETİ ÜZERİNDE EDA VE MÜŞTERİ SEGMENTASYONU

Veri Bilimi Dönem Projesi Raporu
Ayşe Esra Arslan --- Öğrenci No: 1306240093

1. Problem Tanımı

Bu projede bir e-ticaret firmasının satış verileri üzerinden üç soruya cevap aranmıştır:

1. Firma en çok hangi ülkelerden ve hangi ürünlerden gelir kazanıyor?
2. Satışlarda zaman içinde belirgin bir artış/azalış ya da mevsimsel bir desen var mı?
3. Müşteriler satın alma davranışlarına göre birbirinden farklı gruplara ayrılabilir mi?

Bu üç soru seçildi çünkü bir e-ticaret işletmesinin pazarlama bütçesini doğru yere yönlendirmesi ve müşterisini elinde tutabilmesi büyük ölçüde bu tür bilgilere bağlıdır.

2. Veri Seti ve Kaynağı

Projede UCI Machine Learning Repository'de yer alan "Online Retail" veri seti kullanılmıştır (Chen, D., 2015, <https://doi.org/10.24432/C5BW33>). Veri seti CC BY 4.0 lisansı ile paylaşılmıştır, yani kaynak belirtilerek özgürce kullanılabilir.

Veri seti Birleşik Krallık merkezli, mağazası olmayan (yalnızca online satış yapan) bir hediyelik eşya firmasının 1 Aralık 2010 - 9 Aralık 2011 arasındaki tüm satış işlemlerini içeriyor. Firma genelde özel günler için hediyelik ürünler satıyor ve müşterilerinin önemli bir kısmı toptancı. Ham veri 541.909 satır ve 8 sütundan oluşuyor: InvoiceNo, StockCode, Description, Quantity, InvoiceDate, UnitPrice, CustomerID, Country.

3. Yöntem

3.1 Veri Temizleme

Ham veriye sırasıyla şu işlemler uygulandı:

- CustomerID'si boş olan 135.080 satır çıkarıldı. Bu satırlar büyük olasılıkla kayıt olmadan yapılan alışverişlere ait ve müşteri bazlı bir analiz yapılacağı için kullanılamıyordu.
- Fatura numarası "C" ile başlayan satırlar (iptal/iade işlemleri) çıkarıldı, çünkü bunlar gerçek bir satışı temsil etmiyor.
- Quantity veya UnitPrice değeri 0 veya negatif olan satırlar da aynı sebeple çıkarıldı.
- CustomerID sütunu tam sayıya çevrildi (ondalıklı görünüyordu, ama bir müşteri numarasının ondalıklı olması mantıksız). Ayrıca Quantity × UnitPrice ile her satır için toplam tutarı veren TotalPrice sütunu eklendi.

Bu işlemlerden sonra veri seti 397.884 satıra indi (orijinalin yaklaşık %73,4'ü).

Quantity ve UnitPrice sütunlarında boxplot ile aykırı değer incelemesi yapıldı ve gerçekten uç değerler olduğu görüldü. IQR yöntemine göre hesaplanan üst sınır ($Q3 + 1,5 \times IQR$) çok düşük çıktı (27,0) ve bu sınırın üzerinde 25.647 satır (verinin %6,4'ü) vardı. Bu kadar satırı silmek, veri setinin kendi açıklamasında belirtilen toptancı müşterilerin gerçek satışlarını da silmek anlamına gelebilirdi. Bu yüzden satırları silmek yerine, Quantity ve UnitPrice değerleri 99. yüzdilik dilime kırıldı (capping). Böylece hem aşırı uç değerlerin kümeleme modelini bozması önlendi hem de veri kaybı en aza indirildi.

Not: Bölüm 3.2'deki (EDA) sayılar ve grafikler verinin gerçek dağılımını olduğu gibi göstermek amacıyla ham, kırılmamış haliyle hesaplanmıştır. Bölüm 3.3'teki kümeleme modelinde ise yukarıda açıklanan capped veri kullanılmıştır; bu nedenle iki bölüm arasında küçük sayısal farklar görülebilir, bu kasıtlı bir tercihtir.

3.2 Keşifsel Veri Analizi

Veri temizleme aşamasının ardından elimizde 37 farklı ülkeye ait 18.532 fatura, 4.338 müşteri ve 3.665 farklı ürüne dair bilgi kaldı; toplam satış geliri ise yaklaşık 8,9 milyon sterlin olarak hesaplandı. Analiz sürecinde verinin yapısını daha iyi kavrayabilmek adına, dört farklı grafik türünü içeren toplam beş görselleştirme yapıldı. Bu kapsamda; ülkelere göre gelir dağılımı ve en çok satılan ürünleri incelemek için sütun grafikleri (bar chart), aylık gelir trendini görmek için çizgi grafiği (line chart) ve fatura başına düşen sipariş tutarlarının dağılımını anlamak için logaritmik ölçekli bir histogram kullanıldı. Son olarak, miktar (Quantity) ve birim fiyat (UnitPrice) verilerindeki aykırı değerleri gözlemleyebilmek için yine logaritmik ölçekli kutu grafiklerinden (boxplot) faydalanıldı.

3.3 Modelleme: RFM Analizi ve K-Means Kümeleme


Müşterileri segmentlere ayırmak amacıyla RFM (Recency, Frequency, Monetary) analizi uygulandı. Öncelikle her bir müşteri için son alışverişin üzerinden geçen süre (Recency), kesilen fatura sayısı (Frequency) ve toplam harcama tutarı (Monetary) hesaplandı. Bu üç metrik birbirinden çok farklı ölçeklere sahip olduğu için (örneğin Monetary değeri binlerce sterlini bulurken, Frequency değeri 1-200 arasında değişiyordu), modelin tutarlılığı adına tüm değerler StandardScaler kullanılarak standardize edildi.

Ardından, en uygun küme sayısını bulmak amacıyla Elbow yöntemiyle $k=1$ 'den $k=10$ 'a kadar denemeler yapıldı. Hesaplanan inertia değerleri incelendiğinde; $k=1$ 'den $k=6$ 'ya kadar olan değerlerin sırasıyla yaklaşık 13.000, 8.900, 5.300, 3.900, 3.050 ve 2.700 olduğu görüldü. Düşüş hızının $k=4$ 'ten sonra belirgin bir şekilde yavaşlaması nedeniyle ($k=3$ 'ten 4'e geçerkenki düşüş 1.400 iken, $k=5$ 'ten 6'ya geçişte bu düşüş sadece 350'ydi) optimum küme sayısı 4 olarak belirlendi ve müşteriler K-Means algoritmasıyla 4 ayrı segmente ayrıldı.

4. Bulgular

Soru 1 --- Gelire En Çok Katkı Sağlayan Ülkeler ve Ürünler Nelerdir?


Yapılan incelemelerde, toplam gelirin yaklaşık %82,0'nın Birleşik Krallık'tan elde edildiği görülmüştür (Şekil 1). Bu durum, veri setinin Birleşik Krallık merkezli ("UK-based") bir firmaya ait olmasıyla doğrudan uyumluluk göstermektedir. Hollanda, İrlanda ve Almanya gibi diğer ülkelerin toplam gelir içindeki paylarının ise oldukça düşük seviyelerde kaldığı gözlemlenmiştir. Ürün bazında bakıldığında, en çok satışı yapılan ürünlerin ("Paper Craft Little Birdie", "Medium Ceramic Top Storage Jar" vb.) genellikle dekoratif ev eşyaları ve hediyelik ürünlerden oluştuğu tespit edilmiştir. Elde edilen bu bulgu, firmanın hediye odaklı bir satış profiline sahip olduğu bilgisini doğrulamaktadır.



Şekil 1: Ülkelere göre toplam satış geliri

Soru 2 --- Zaman içinde belirgin bir trend var mı?

Aylık gelir dağılımı incelendiğinde (Şekil 2), satışların Şubat ayında en düşük seviyeyi gördüğü, ancak Eylül ve Kasım ayları arasında ivme kazanarak hızlı bir yükselişe geçtiği anlaşılmaktadır. Bu durum, firmanın hediyelik eşya sektöründe faaliyet göstermesi sebebiyle yaklaşan yıl sonu alışveriş sezonunun bir yansıması olarak değerlendirilebilir. Öte yandan, grafikte Aralık 2011'de görülen sert düşüş mevsimsel bir azalışı temsil etmemektedir; bu görünüm, veri setinin ilgili ayın tamamını değil, yalnızca ilk 9 gününü içermesinden kaynaklanan teknik bir durumdur.



Şekil 2: Aylara göre toplam satış geliri


Soru 3 --- Müşteri segmentasyonu anlamlı sonuç veriyor mu?

Uygulanan K-Means modeli sonucunda müşteri tabanı 4 farklı segmente ayrılmıştır. Oluşturulan bu kümelerin karakteristik RFM profilleri Tablo 1'de özetlenmektedir:

Segment	Müşteri Sayısı	Recency (gün)	Frequency (fatura)	Monetary (£)
Şampiyon / Toptan	11	5,1	91,6	96.357
Sadık Yüksek Değerli	197	12,1	23,0	10.930
Standart	3.060	43,6	3,7	1.296
Pasif / Kayıp Riski	1.070	248,1	1,6	454,6

Tablo 1: K-Means ile oluşturulan müşteri segmentlerinin RFM profili

Tablodaki veriler incelendiğinde, "Şampiyon/Toptan" grubunun sayıca oldukça küçük (yalnızca 11 kişi) olmasına karşın, ortalama harcama tutarı (£96.357) ve fatura sıklığı (91,6) bakımından diğer tüm grupları açık ara geride bıraktığı görülmektedir. Bu durum, söz konusu grubu firma açısından son derece değerli kılmaktadır. Öte yandan, 3.060 kişiden oluşan "Standart" grup genel müşteri tabanının büyük bir çoğunluğunu temsil ederken; 1.070 kişilik "Pasif / Kayıp Riski" grubunun son alışverişinin üzerinden ortalama 248,1 gün (yaklaşık 8 ay) geçtiği ve bu kitlenin firmayı terk etme eğiliminde olduğu tespit edilmiştir (Şekil 3). Elde edilen bu dağılım, modelin müşteri davranışlarındaki belirgin farklılıkları ayırtmada başarılı olduğunu göstermektedir.



Şekil 3: Müşteri segmentleri (RFM kümeleme sonucu)

Not: Dört segmentteki müşteri sayılarının toplamı $11 + 197 + 3.060 + 1.070 = 4.338$ 'dir; bu sayı, Bölüm 3.2'de hesaplanan toplam benzersiz müşteri sayısı (4.338) birebir örtüşmektedir. Bu, hiçbir müşterinin kümeleme dışında kalmadığını ve modelin doğru çalıştığını teyit eder.

Elde edilen bu tablo aslında ticari açıdan beklenen bir durumu yansıtıyor: Müşteri tabanının çok küçük bir kısmı toplam gelirin büyük bir bölümünü sağlarken, çoğunluk daha düşük veya orta düzeyde bir maddi katkı sunuyor. Firma, bu segmentasyon sonuçlarını stratejik olarak değerlendirerek pasif müşteriler için geri kazanım kampanyaları düzenleyebilir ve "şampiyon" olarak nitelendirilen sadık müşterilerine özel avantajlar sunarak onları elinde tutabilir..

5. Sınırlamalar

- Veri seti sadece bir yıllık bir dönemi kapsıyor, bu yüzden gözlenen mevsimsel desenin her yıl tekrar edip etmeyeceği bu çalışmada test edilemedi.
- CustomerID'si boş olan 135.080 satır analiz dışı bırakıldı, dolayısıyla gerçek satış hacminin bir kısmı müşteri segmentasyonuna dahil olmadı.
- Aykırı değerler silinmek yerine kırıldı (capping); bu, gerçek toptan satış davranışının bir kısmını hafifletmiş olabilir.
- K-Means kümelerin nispeten dengeli/küresel dağıldığını varsayar, gerçek müşteri davranışı bu varsayıma tam uymayabilir. Ayrıca segmentasyon sadece RFM metriklerine dayanıyor; ürün kategorisi ya da konum gibi başka bilgiler modele dahil edilmedi.

6. Öğrenilenler

Bu proje, teorik veri bilimi kavramlarının gerçek dünya verilerine nasıl uygulanacağı konusunda önemli pratik tecrübeler edinmemi sağladı. Süreç boyunca elde ettiğim temel kazanımları şu şekilde özetleyebilirim:

- **İş Bağlamının (Domain Knowledge) Veri Ön İşlemeye Etkisi:** Veriyi temizlerken alınacak kararların sadece istatistiksel kurallara dayanmaması gerektiğini anladım. Aykırı değerleri doğrudan veri setinden çıkarmak yerine sınırlandırma (capping) işlemini tercih etmem, e-ticaret sektöründeki "toptancı müşteri" gerçeğini modele doğru bir şekilde yansıtmamı sağladı.
- **Doğru Görselleştirme Tekniklerinin Önemi:** Finansal metrikler gibi sağa çarpık (skewed) dağılım gösteren verileri incelerken, logaritmik ölçek kullanmanın grafikleri çok daha okunabilir kıldığını ve veri içindeki gizli eğilimleri ortaya çıkardığını uygulamalı olarak deneyimledim.
- **Modelin Karmaşıklığı ve İş Değeri İlişkisi:** RFM analizi ile K-Means kümeleme algoritmalarının birleşiminin, yapısı gereği çok karmaşık olmamasına rağmen e-ticaret süreçleri için son derece stratejik, yorumlanabilir ve aksiyona dönüştürülebilir sonuçlar ürettiğini gördüm.

Kaynakça

Chen, D. (2015). Online Retail [Dataset]. UCI Machine Learning Repository.
<https://doi.org/10.24432/C5BW33>